

# 基于神经潜优化的运动学运动重定向学习手语

张浩东, 李伟杰, 刘江品, 陈泽西, 崔玉祥, 王玥, 熊荣

**摘要-**从人的演示到机器人的运动重定向是降低机器人编程专业要求和工作量的有效途径, 但面临着人与机器人差异带来的挑战。传统的基于优化的方法耗时且严重依赖于良好的初始化, 而最近使用前馈神经网络的研究对看不见的运动泛化效果较差。此外, 它们忽略了人类骨骼和机器人结构中的拓扑信息。在本文中, 我们提出了解码器来建立潜在空间和机器人运动空间之间的映射。之后, 通过搜索最优潜向量, 即可获得满足机器人约束的重定向结果。除了潜在优化之外, 神经初始化还利用编码器提供更好的初始化, 以实现更快更好的优化收敛。人类骨骼和机器人结构都被建模为图, 以便更好地利用拓扑信息。我们对中国手语进行了重定向实验, 这涉及到两只手臂和两只手, 对关节之间的相对关系有额外的要求。实验包括将各种人类演示重新定位到模拟环境中的 YuMi、NAO 和 pepperi, 以及真实世界环境中的 YuMi。验证了所提方法的效率和准确性。

**索引术语**——从示范、模仿学习中学习。

我的介绍。

**M**OTION 重定向通过学习人类演示来简化机器人编程, 可以有效地降低对编程专业知识的要求, 实现对复杂机器人动作的快速学习。在本文中, 我们专注于生成运动学上可行的机器人运动, 这可以帮助机器人用肢体语言表达特定的信息或情感。如今, 它已被应用于娱乐公园中的人形机器人[1]和用于与听力受损者交流的手语机器人[2]。此外, 它还可以用于博物馆或餐馆的服务机器人, 通过肢体动作与人进行互动。具体来说, 我们

稿件收到 2021 年 9 月 9 日; 2022 年 1 月 27 日收稿。发表日期 2022 年 2 月 14 日; 当前版本日期 2022 年 2 月 28 日。副主编 N. Figueroa 和编辑 J. Kober 在对审稿人的意见进行评估后, 推荐发表这封信。本文由中国国家自然科学基金资助, 基金号: 62173293。(通讯作者: 王悦荣 Xiong)。

作者与浙江大学工业控制与技术国家重点实验室合作, 浙江杭州 310027 (e-mail: aqz@zju)。  
edu.cn; liweijie@zju.edu.cn; jiangpin@zju.edu.cn; chen zexi@zju.edu.cn; yux -  
iangcui@zju.edu.cn; wangyue@ipc.zju.edu.cn; rxiong@zju.edu.cn)。

数字对象标识符 10.1109/LRA.2022.3151433

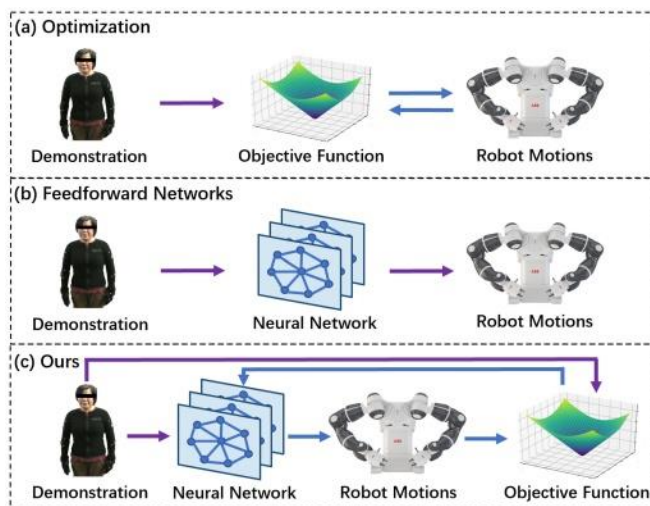


图 1 所示。不同运动重定向方法示意图。(一)优化方法。(b)前馈网络方法。(c)我们的方法。紫色箭头表示前馈传递, 蓝色箭头表示迭代传递。

对看不见的手语任务执行动作重定向, 其中包括复杂的双臂运动和手指运动。然而, 由于人类和机器人之间的差异, 这仍然是一个持续的挑战。即使是结构与人类相似的类人机械臂, 在自由度、运动学参数和物理约束等方面也存在差异。再加上对相似性、安全性、快速性的各种要求, 使得问题变得难以解决。

以前的工作已经发展到解决这个问题。直接映射[3]通过人类定义的映射关系来转换人类运动, 但很难手动定义。基于逆运动学[4]的方法已经被用来保持机器人末端执行器的位置与人类的位置一致, 而它不考虑机器人的约束和其他关节的相似性。为了克服这些问题, 已经提出了基于优化的方法来寻找运动相似性最大化并满足机器人执行能力的最优解[2], [5], [6]。通常是通过定义和优化带有约束的目标函数来实现的。虽然这些方法能够产生有希望的重定向结果, 但它们必须花费大量时间来优化每个运动, 并且初始化不良可能导致不良的局部最小值。

2377-3766©2022 IEEE。允许个人使用, 但重新发布/再分发需要 IEEE 许可。更多信息请参见 <https://www.ieee.org/publications/rights/index.html>。

授权许可使用仅限于: 上海大学。下载于 2023 年 12 月 27 日 03:31:34 UTC 从 IEEE 探索。限制适用。

隐式运动是近年来的研究热点之一，将隐式空间应用于不同的任务中也有些工作[7]-[9]。Ichter 等人[7]引入了一种基于rrt的算法，直接在潜在空间中规划运动，用于视觉规划和人形机器人规划。Watter 等人[8]提出了一种局部线性潜在动力学模型，用于从原始像素图像进行控制。然而，这些方法不能直接应用于运动重定向任务，因为它们没有考虑运动相似度。一种基于强化学习的方法[10]倾向于通过为重定向运动设计奖励来解决这个问题。Choi 等人[11]提出了一种数据驱动的运动重定向方法，该方法利用基于优化方法的结果作为训练的基础真理。然而，由于训练数据有限，这些方法可能在看不见的运动上表现不佳，从而导致机器人运动不准确或不可行的。

在本文中，我们提出了一种利用神经网络和优化的优点的神经潜在优化方法，如图 1 所示。具体来说，我们首先将运动重定向制定为约束优化问题，并在深度解码器的帮助下将其转换为无约束问题。解码器学习从潜空间到therobtmotionspace的映射。对于 anyunseenmotion，我们进一步寻找最小化目标函数的最优潜码。为了加速优化过程并帮助收敛到更好的结果，我们利用深度编码器为潜在代码生成更好的初始值。将人体骨架和机器人结构建模为图，可以更好地利用拓扑信息，具有更好的泛化性。图编码器和图解码器是端到端训练的。据我们所知，这是第一个利用神经潜在优化从人类到机器人的运动重定向的工作。

我们的贡献可以总结如下：

R 提出了一种新颖的运动学运动重定向框架

通过整合潜在优化和神经初始化，构建人机中文手语数据集，引入潜在优化来提高运动重定向的性能。

在看不见的运动上，并设计神经初始化，为潜在向量提供更好的初始值，其中  $\mathbf{r}$  将人类骨骼和机器人结构建模为图形，有助于更快更好地收敛。

从而可以捕获拓扑结构的固有信息，具有更好的泛化。

2. 相关工作

A. 从示范中学习

从演示中学习一直是机器人研究中的一个基本问题，并且在工业应用中具有很大的前景，因为它使机器人无需编程即可模仿人类技能[12]。最近的研究表明，从演示中学习取得了进展。Hamaya 等人[13]提出了一种通过从人类演示中设计奖励函数来学习软机器人装配策略的方法。Lee 等人[14]提出了一种混合生成对抗模仿学习方法，该方法结合了专家演示和负面演示。Cai 等人[15]引入了一个框架

以几何零空间的形式从人类演示中学习技能，从而推断出一个独立于机器人运动学或环境的参数化的基于约束的技能模型。与这些方法不同，我们旨在解决人-机器人运动重定向问题，其中机器人模仿人类运动，同时保持运动相似性并满足机器人的运动学约束。

B. 基于优化的运动重定向

以前的工作试图用优化来解决运动学运动重定向问题。通过以迭代的方式优化预定义的运动学相似性目标函数，这些方法最大限度地减少了机器人运动与人类演示之间的差距。Liang 等人[2]提出了一种利用图优化和动态运动原语(Dynamic Movement Primitives)的运动重定向方法。Wang 等人[6]提出了一个使用单个深度传感器的运动重定向生成框架。Choi 等人[5]设计了一个由运动重定向描述、优化、逆运动学和轨迹后处理组成的运动重定向流水线。然而，这些方法在计算上很昂贵，并且需要很长的迭代过程来进行优化。而且，由于目标函数复杂，它们也容易在没有良好初值的情况下陷入糟糕的局部最小值。作为比较，我们建议利用图解码器对潜在空间而不是机器人运动空间进行优化。我们还引入了一个图编码器来为优化提供更好的初始值，这可以加速迭代过程。

C. 基于学习的运动重定向(Learning-Based Motion Retargeting)

大多数基于学习的方法都集中在计算机图形学中动画角色的运动重定向上。Aberman 等人[16]引入了可微的骨骼感知卷积、池化和解池算子，用于不配对的运动重定向。他们还提出了一种重定向视频捕获运动的方法[17]。Villegas 等人[18]提出了一种具有正运动学层和基于周期一致性的对抗训练目标的递归神经网络。尽管这些方法在动画人物中取得了令人印象深刻的结果，但它们不能直接应用于人-机器人运动重定向，因为它们没有考虑机器人的运动学约束，会产生不可行的机器人运动。对于人机运动重定向，Kim 等人[10]开发了一种基于深度强化学习的循环三相优化方法。Choi 等人[11]提出了一种结合非参数回归和深潜变量建模的数据驱动运动重定向方法。然而，由于训练数据的数量和多样性有限，这些方法在看不见的运动中可能表现不佳，导致机器人运动不准确或不可行的。作为对比，我们的方法进一步优化了任何看不见的运动的潜在代码，这可以提高性能，并将神经网络和优化的优点结合起来。此外，我们的方法不仅考虑了手臂运动，还考虑了复杂的手指运动。

3. 问题陈述

在本节中, 我们重点关注运动重定向问题, 该问题需要生成运动学上可行的机器人运动, 并将该问题表述为最小化目标函数, 该目标函数考虑了运动相似性和机器人运动学约束。假设我们有一个人体演示的帧, 记为  $D$ , 它代表了该帧下所有人体关节的姿态。那么运动重定位的目标就是最小化机器人运动和人类演示之间的差异。虽然存在几种不同的方式来表示机器人运动, 但我们建议使用关节角度而不是关节位置, 然后使用可微分的正运动学模块计算关节位置。这样的表示可以避免关节长度的变化和逆运动学的多个解。因此机器人的运动可以用  $K(\mathbf{r})$  来表示, 其中  $\mathbf{r}$  为机器人关节角度,  $K$  为正运动学模块。最后, 运动重定向的目标可以表述为:

$$\begin{aligned} &\underset{\mathbf{r}}{\text{minimize}} \quad L(D, K(\mathbf{r})) \\ &\text{subject to} \quad \mathbf{r}_{lower} \leq \mathbf{r} \leq \mathbf{r}_{upper} \end{aligned} \tag{1}$$

其中  $L$  为衡量机器人运动与人类演示差异的目标函数,  $\mathbf{r}_{lower}$  和  $\mathbf{r}_{upper}$  为关节角度的上限和下限。

为了使人体运动尽可能接近人体演示并在运动学上可行, 总体目标函数由末端执行器损失  $L_{ee}$ 、方向损失  $L_{ori}$ 、肘部损失  $L_{elb}$ 、手指损失  $L_{fin}$  和碰撞损失  $L_{col}$  五个项组成, 其中  $\lambda_{ee}$ 、 $\lambda_{ori}$ 、 $\lambda_{elb}$ 、 $\lambda_{fin}$  和  $\lambda_{col}$  分别为它们的权值, 其大小分别为 1000、100、100、100 和 1000。整体目标函数需要进行修改, 以适应其他任务。例如, 对于物体抓取和操纵任务, 应该重新设计末端执行器损失和手指损失, 并需要额外的姿态估计模块。

$$L = \lambda_{ee}L_{ee} + \lambda_{ori}L_{ori} + \lambda_{elb}L_{elb} + \lambda_{fin}L_{fin} + \lambda_{col}L_{col} \tag{2}$$

1)末端执行器损耗:末端执行器损耗  $L_{ee}$  鼓励机器人匹配人类演示的末端执行器位置, 并使用均方误差比较归一化末端执行器位置的差异。归一化系数是指从肩膀到手腕的实际长度。设  $\mathbf{p}_j$  和  $\mathbf{l}_j$  为末端执行器  $j$  的位置和归一化系数,  $\hat{\mathbf{p}}_j$  和  $\hat{\mathbf{l}}_j$  为演示的对应变量。则  $L_{ee}$  定义为:

$$L_{ee} = \sum_j \left\| \frac{\mathbf{p}_j}{\mathbf{l}_j} - \frac{\hat{\mathbf{p}}_j}{\hat{\mathbf{l}}_j} \right\|_2^2 \tag{3}$$

2)方向损失:方向损失  $L_{ori}$  是通过比较末端执行器方向的差异来计算的, 也使用均方损失。设  $\mathbf{R}_j$  和  $\hat{\mathbf{R}}_j$  分别为机器人和人的末端执行器旋转矩阵  $j$ 。然后

$L_{ori}$  为:

$$L_{ori} = \sum_j \left\| \mathbf{R}_j - \hat{\mathbf{R}}_j \right\|_2^2 \tag{4}$$

3)肘关节丢失:肘关节丢失  $L_{elb}$  鼓励其他关节的运动与演示相似。它是通过比较从肘关节到手腕的归一化向量的差异来计算的。归一化系数是从肘部到手腕的实际长度。设  $\mathbf{p}^{wrist}_j$ 、 $\mathbf{p}^{elbow}_j$ 、 $\mathbf{l}_{we}$  分别为腕部位置、肘部位置和机器人手臂  $j$  的归一化系数,  $\hat{\mathbf{p}}^{wrist}_j$ 、 $\hat{\mathbf{p}}^{elbow}_j$ 、 $\hat{\mathbf{l}}_{we}$  分别为演示的对应变量。则  $L_{elb}$  计算为:

$$L_{elb} = \sum_j \left\| \frac{\mathbf{p}^{wrist}_j - \mathbf{p}^{elbow}_j}{\mathbf{l}_{we}} - \frac{\hat{\mathbf{p}}^{wrist}_j - \hat{\mathbf{p}}^{elbow}_j}{\hat{\mathbf{l}}_{we}} \right\|_2^2 \tag{5}$$

3)手指丢失:手指丢失  $L_{fin}$  鼓励机器人模仿人类的手指动作, 这是手语的重要组成部分。它比较从掌指关节到指尖的向量, 通过手指长度归一化。设  $\mathbf{p}^{tip}_j$ 、 $\mathbf{p}^{meta}_j$  和  $\mathbf{l}_{tm}$  为指尖位置, 为掌指关节位置, 为机器人手指  $j$  的归一化系数,  $\hat{\mathbf{p}}^{tip}_j$ 、 $\hat{\mathbf{p}}^{meta}_j$  和  $\hat{\mathbf{l}}_{tm}$  为

演示中对应的变量。则  $L_{fin}$  定义为:

$$L_{fin} = \sum_j \left\| \frac{\mathbf{p}^{tip}_j - \mathbf{p}^{meta}_j}{\mathbf{l}_{tm}} - \frac{\hat{\mathbf{p}}^{tip}_j - \hat{\mathbf{p}}^{meta}_j}{\hat{\mathbf{l}}_{tm}} \right\|_2^2 \tag{6}$$

4)碰撞损失:碰撞损失  $L_{col}$  用于惩罚导致碰撞的机器人运动。我们将机器人手臂的链接建模为胶囊, 并计算胶囊对之间的距离。如果这个距离小于不发生碰撞的最小距离, 则计算损失。设  $d_{i,j}$  为胶囊  $i$  与胶囊  $j$  之间的距离,  $d_{min}$  为无碰撞阈值。则  $L_{col}$  为:

$$L_{col} = \sum_{d_{i,j} < d_{min}} e^{-d_{i,j}^2} \tag{7}$$

神经潜优化

一类传统方法试图通过增加联合极限损失  $L_{lim}$  作为软约束来解决(1)中的约束优化问题。新的目标函数  $L_{new}$  被公式化为(8), 然而, 目标函数高度非凸, 使得这些方法很难很好地求解。主要原因如下:1)初始化不好可能导致局部最小值不好, 优化过程也很耗时;2)由于  $L_{lim}$  不可能被最小化到零, 优化结果可能会超过关节极限。

$$L_{new} = L + \lambda_{lim}L_{lim} \tag{8}$$

相比之下, 我们的方法旨在借助潜在优化和神经初始化来克服这些缺点。如图 2 所示, 我们建议在潜在空间而不是机器人运动空间中进行优化, 其中潜在向量通过图解码器映射到硬约束机器人运动。






图 2 所示。我们方法的总体框架。我们用图形解码器建立了潜在空间和机器人运动空间之间的映射关系。利用人类演示和机器人运动之间的差异，我们搜索通过梯度下降最小化差距的最优潜在代码  $z^*$ 。潜在码  $z$  的初始值由神经初始化而不是随机初始化提供，从而提高了收敛速度。

此外，我们利用深度图编码器提供更好的初始化，从而提高了收敛速度和结果。

A. 潜在优化

我们首先描述如何将约束优化问题转化为无约束优化问题。为了约束输出关节缠结，实际中总是使用非线性激活函数。这里我们使用  $\tanh$  将输出绑定到一个有限的范围。然后将输出线性地重新映射到机器人关节角度的上下限，这样就保证了关节极限约束得到满足。

1) 自解码器: 为了提高对看不见的运动的性能，我们建议采用自解码器[19]架构，我们选择在潜在空间而不是机器人运动空间中优化目标函数。为了实现这一点，我们引入了一个潜在向量  $z$  作为机器人运动的潜在嵌入。不同的潜码对应不同的机器人运动。利用深度解码器  $f_\psi$  建立潜空间与机器人运动空间之间的联系，其中， $\psi$  是解码器的可学习参数。解码器的目标是将潜在向量映射到相应的机器人运动，该运动借助非线性激活函数坚持联合极限约束。训练解码器的一种简单方法是通过梯度下降法将解码器的参数  $f_\psi$  和潜在向量  $z$  联合优化为(9)，模型同时学习映射函数，并为每个运动找到最优的潜在码。设计正则化项是为了使潜在空间接近于均值为 0，方差为  $\sigma$  的多元高斯分布。选择方差  $\sigma$  为 1，类似于变分自编码器[20]。关于使用潜在空间的动机的更多细节可以在附录 [21]中找到。

$$\min_{z, \psi} L(D, K(f_\psi(z))) + \frac{1}{\sigma^2} \|z\|_2^2 \tag{9}$$

2) 基于优化的推理: 在推理时，从高斯分布(10)中采样  $z$  的初始值，记为  $z_0$ 。我们保持解码器的参数固定，并通过梯度下降搜索最优潜在码  $z^*$  为(11)。这是一个如下的迭代过程: 1) 采样一个初始值  $z_0$ ; 2) 解码相应的机器人运动; 3) 计算目标函数的损失; 4) 通过梯度下降优化潜码。通过这种方式，我们可以为任何看不见的运动生成最好的可能结果。

$$z_0 \sim \mathcal{N}(0, \sigma^2) \tag{10}$$

$$z^* = \operatorname{argmin}_z L(D, K(f_\psi(z))) + \frac{1}{\sigma^2} \|z\|_2^2 \tag{11}$$

在为每个运动搜索最优的潜在代码之后，我们的方法可以为看不见的运动提供有希望的结果。但是，由于随机初始化，它仍然存在一些缺点。从随机值开始优化过程非常耗时。而且，不同的随机初始化方式可能导致不同的收敛结果，如果没有一个好的初始值，很容易陷入一个不好的局部最小值。

B. 神经初始化

1) 编码器作为初始化: 为了克服随机初始化的缺点，我们引入了参数化编码器  $f_\phi$ ，以提供更好的初始化，从而更快更好地收敛，其中  $\phi$  为编码器的参数。编码器以人的演示作为输入，生成一个更好的初始值  $z_0$ ，它应该接近最优的潜在码  $z^*$ ，这样潜在优化将需要更少的迭代来收敛，并降低陷入坏的局部最小值的概率。在训练时，我们同时对编码器  $f_\phi$  和解码器  $f_\psi$  的参数进行优化:

$$\min_{\psi, \phi} L(D, K(f_\psi(f_\phi(D)))) + \frac{1}{\sigma^2} \|f_\phi(D)\|_2^2 \tag{12}$$

在推理时间上,与直接输出结果的前馈网络不同,编码器为每个人类演示找到一个良好的初始值  $\mathbf{z}_0$  为(13)。然后潜在优化从这个初始值  $\mathbf{z}_0$  开始,通过梯度下降搜索最佳潜在代码,如(14)。最大迭代次数设置为 100 次,停止准则为连续 5 次迭代达到最大迭代次数或损失不减小。

$$\mathbf{z}_0 = f_{\phi}(D) \tag{13}$$

$$\mathbf{z}^* = \operatorname{argmin}_{\mathbf{z}} L(D, K(f_{\psi}(\mathbf{z}))) + \frac{1}{\sigma^2} \|\mathbf{z}\|_2^2 \tag{14}$$

C. 基于图形的编码器和解码器

设计编码器和解码器的常见选择是将所有关节的特征连接起来,并通过一个完全连接的网络传递它们。然而,人和机器人的结构具有丰富的拓扑信息,这些信息可能会在全连接层中丢失。将人体骨架和机器人结构表示为图形是一种更自然的方式,其中每个节点对应于人或机器人的一个关节,每个边代表关节之间的连接关系。图表示对节点和边的排列是不变的,并且在许多任务中已经证明了其提取人体骨骼相关信息的有效性[22]-[24]。在附录[21]中进一步讨论了它的优势。在运动重定向任务中,我们选择将数据表示为图而不是向量,以更好地捕获拓扑信息。

考虑一个图  $G=(V, E)$ , 其中包含特征维数为  $C_1$  的  $N$  个节点的集合,记为  $V \in \mathbb{R}^{N \times C_1}$ , 以及特征维数为  $C_2$  的  $M$  条边的集合,记为  $E \in \mathbb{R}^{M \times C_2}$ 。这个图可以是人体骨架图,也可以是机器人结构图。设  $\mathbf{x}$  为节点  $i$  的特征,  $N(i)$  为节点  $i$  的邻居节点集合,  $\mathbf{e}_{j,i}$  为节点  $j$  到节点  $i$  的边缘特征, 对于节点  $i$  的每个邻居节点  $j$ , 我们首先将它们的节点特征和边缘特征连接起来,记为  $\mathbf{z}_{i,j} = [\mathbf{x}_i, \mathbf{x}_j, \mathbf{e}_{j,i}]$ 。然后通过非线性映射获得每个邻居节点的消息,并通过求和将所有信息聚合起来。最后,我们通过将聚合结果添加到原始特征中,以残差方式更新节点  $i$  的特征。节点特征的更新公式如下:

吗?

$$\mathbf{x}_i' = \mathbf{x}_i + \sum_{j \in N(i)} g(\mathbf{W}_f \mathbf{z}_{i,j} + \mathbf{b}_f) \tag{15}$$

式中  $g$  为 LeakyReLU 激活函数,  $\mathbf{w}_f$  和  $\mathbf{b}_f$  为可学习参数。

构建的三种不同机器人的人体骨架图和机器人结构图如图 3 所示。具体来说,在人体骨架图中,每个节点的输入特征是人体关节的位置和旋转,而边缘特征是人体关节之间的偏移量。另一方面,在机器人结构图中,每个节点的输出特征表示对应机器人关节的旋转角度,而边缘特征则是机器人链路之间的初始偏移量和旋转。人体骨架图和机器人结构图都是有向图。我们假设有两种类型的节点,这取决于关节是否被定位




图 3 所示。在仿真环境中,我们提出的方法在三个不同的机器人上传输的“Can”序列快照。从第一排到最后一排分别是人类演示者 Pepper、NAO、YuMi。第一列是对应的人体骨架图或机器人结构图。




图 4 所示。网络体系结构。

在胳膊上,还是在手里。相同类型的节点共享相同的图卷积权值。通过叠加多层图卷积,模型可以更有效地利用拓扑结构的固有信息,学习深层次特征。

D. 网络架构

网络架构如图 4 所示。该模型由一个图编码器、一个图解码器和一个正运动学模块组成。图编码器由三层图卷积组成,这三层图卷积将输入特征的通道从 3 扩展到 16,32 和 64。由于人体骨架图中的节点数可能与机器人结构图不同,因此我们使用线性层将图编码器的输出特征映射到潜在代码。潜在码与机器人关节的上下限拼接后,被馈送到图解码器中。

图解码器也由三层图卷积组成,它将输出特征的通道细化为 32、16 和 1。通过  $\tanh$  激活函数,解码器的输出特征被限制在-1 到 1 的范围内。然后将它们线性地重新映射到每个机器人关节的上限和下限。这样就保证了每个关节角度都在

机器人的关节极限。最后，利用正运动学层将输出关节角度转换为关节位置。正运动学被用作一个可微但不需要学习的网络模块，它允许我们在目标函数上进行优化。

诉实验

A. 实验设置

我们对三种不同的机器人，包括 ABB 的 YuMi 双臂机器人、NAO 和 Pepper，进行了从中国手语运动重定向的实验。ABB 的 YuMi 双臂机器人包含 14 个自由度，并配备了 Inspire-Robotics 公司的灵巧双手，每只手有 6 个自由度和 12 个关节。对于 NAO 和 Pepper，我们只使用它们的机械臂，它们有 10 个自由度。机器人参数是从统一的机器人描述格式中解析出来的，包括初始偏移量、初始旋转、关节角度的上限和下限。机器人坐标系的原点设置在其两个肩关节的中心，z 轴为垂直方向，x 轴为前进方向，y 轴为左手方向。

这些中文设计语言是由专业的手语老师表演的，他的肩膀、肘部和手腕的姿势被一种名为 OptiTrack 的高精度光学系统捕捉到。而手指的运动轨迹则由一种名为 WiseGlove 的数据手套获取。位置数据用固定系数归一化，旋转数据用欧拉角表示。人体坐标系的建立方式与机器人相同。总数据包含 5 个日常场景的手语序列，共 86 个序列，13847 帧。收集到的数据集的统计可以在附录[21]中找到。我们将数据分成训练集和测试集，其中训练集包括来自“商业”、“火车站”和“西湖”3 个场景的序列，测试集包括来自“医院”和“介绍”2 个场景的序列。因此，总的训练数据包含 61 个手语序列和 9691 帧，测试数据包含 25 个手语序列和 4156 帧。收集到的数据集将很快开源。

在训练过程中，我们使用 16 个批大小和一个恒定学习率为  $1e-4$  的 Adam 优化器。训练过程耗时 1301 秒，直到模型与 NVIDIA TITAN X GPU 和 Intel(R) Xeon(R) E5-2696 CPU 收敛。

B. 消融研究

1) 初始化选择:为了评估使用深度图编码器为潜在向量提供初始值的好处，我们比较了神经初始化和随机初始化在将测试集中看不见的运动重定向到 YuMi 的任务中的性能。我们使用三个高斯分布进行随机初始化作为比较，其中两个均值为 0，方差为 0.1、0.2，另一个使用训练集的均值和方差。从图 5 中我们可以看到:1)不同的初始化方法会导致不同的收敛结果;2)随机初始化可能会陷入局部极小值;3)

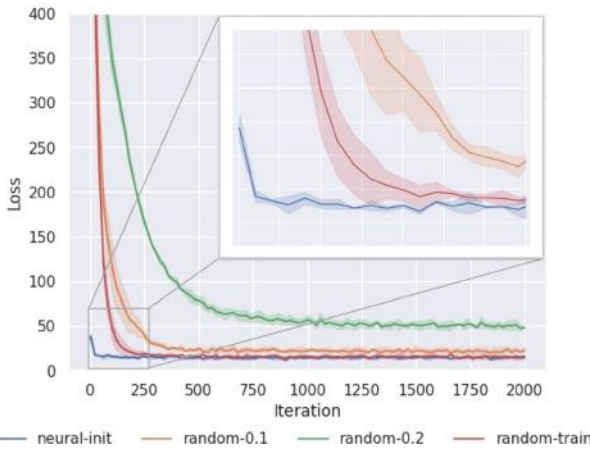


图 5 所示。均值为 0、方差为 0.1、0.2 的高斯分布的神经初始化和随机初始化的收敛结果，以及训练集的均值和方差。

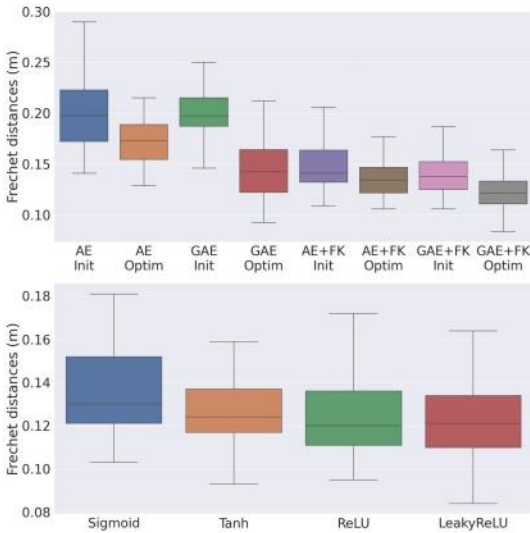


图 6 所示。不同网络架构对测试集中看不见的运动的 Frechet 距离。更多的定量结果可以在附录[21]中找到。

深度图编码器能够提供更好的初始值，有助于更快更好地收敛。

2) 网络架构:为了验证网络架构的有效性，我们对图表示、正运动学和潜在优化的使用进行了对比实验。我们将有和没有图表示的版本称为“AE”和“GAE”。“FK”表示正运动学的使用。“Optim”和“Init”表示是否进行了潜在优化。详见附录[21]。我们还比较了 LeakyReLU 与几种常见激活函数的重定向结果。实验的任务是将测试集中看不见的运动重新定位到 YuMi。从图 6 中，我们可以看到:1)使用图表示有助于更好地泛化看不见的运动;2)使用正运动学作为可微但可学习的网络模块，有助于在目标函数上进行优化;3)潜在空间的优化进一步提高了性能;4)双曲正切，






图 7 所示。我们提出的方法在物理 YuMi 机器人上传递的运动快照。前两行是“我能说手语”，后两行是“给我这个能力”。

ReLU 和 LeakyReLU 实现了相似的结果，LeakyReLU 优于其他。

C. 案例研究

在图 3 中，我们首先展示了在 PyBullet 构建的仿真环境中，从人类演示者到三种不同类型机器人的运动重定向结果[25]。基于它们在结构上与人类演示者的接近性，这些机器人的运动重定向的复杂性按升序排列为 Pepper, Nao 和 YuMi。具体来说，Pepper 和 Nao 的自由度更少，机器人环节的比例更接近人类，而 YuMi 拥有灵巧的双手，结构更复杂。结果表明，我们的方法可以应用于不同结构的机器人，这些结构包括不同的自由度、关节长度和关节极限。此外，我们的方法不仅在结构相对简单的机器人上表现良好，在结构明显复杂的机器人上也表现良好。

D. 比较研究

为了彻底评估我们的方法的性能，我们比较了测试集中四个代表性的基线的未见情绪：

DMPMR[2]是一种基于优化的方法，它将图形优化与动态运动原语(Dynamic Movement Primitives, dmp)相结合。它采用三步优化程序来生成机械手臂的关节角度，并计算 r NMG[5]是一种基于优化的管道，利用线性映射来利用手指关节角度。

链路长度修改和任务空间微调。它包括四个步骤:描述准备、运动优化、逆运动学和后处理。




图 8 所示。我们的神经潜优化方法与基线的比较。我们将我们的方法称为“our”，而不使用基于图的网络设计的版本称为“our -w/o”。数据点越靠近左下角，重定向结果越好，这意味着用更少的推理时间获得更高的相似度。带有上标†的方法在测试集的看不见的运动中产生了不可行的机器人运动。更多的定量结果可以在附录[21]中找到。

r C-3PO[10]是一种循环三相深度强化学习方法。它采用近端策略优化(proximal policy optimization, PPO)[26]算法来学习运动重定向。NN 是一种前馈神经网络，以定量和定性的方式采用所有联合技能。以人体的姿态作为输入，直接输出机器人的关节角度。它以监督学习的方式进行训练，以 DMPMR 的优化结果作为基础真值，类似于[11]。

我们进行实验，将测试集中看不见的运动重新定位到 YuMi 机器人上，比较手腕和肘部的跟踪误差以及优化时间。跟踪误差由平均 Frechet 距离[27]来测量

手腕和肘部运动轨迹。Frechet 距离越小，机器人的运动与演示越相似。其细节可以在附录[21]中找到。为了更好地可视化结果，我们在图 8 中比较了平均 Frechet 距离和优化时间。我们注意到，与基于优化的方法相比，我们提出的方法能够在看不见的运动中以更少的优化时间提供有希望的结果。此外，随着潜在优化迭代次数的增加，我们的方法能够获得更好的运动重定向结果。我们还观察到，C-3PO 和 NN 的表现比基于优化的方法更差，因为它们可能会泛化到看不见的运动，导致一些不准确或不可行的结果。NN 的性能最差，这表明使用优化输出作为训练的基础真理将导致由优化误差和拟合误差组成的累积误差。

E. 真实世界定性实验

我们在 ABB 的 YuMi 双臂协作机器人上进行了现实世界的实验，该机器人配备了 inspiire - robotics 的灵巧双手。机械臂和灵巧手的运动由一台外部计算机控制。如图 7 所示，我们提出的方法生成的机器人运动平滑，与演示者的运动非常接近。在附录[21]中进一步讨论了平滑性。

六. 结论

本文提出了一种基于神经潜优化生成运动学可行机器人运动的人-机器人运动重定向方法。通过在潜在空间中进行优化，我们的方法可以获得比前馈神经网络更好的结果。利用我们的深度图编码器提供的更好的初始化，我们的方法可以比以前基于优化的方法更快地收敛。实验结果表明，我们的方法可以生成可以在物理机器人上执行的光滑和相似的运动。未来的工作将改善它不考虑与环境的物理接触的局限性。

参考文献。

[1]王小明, 王晓明, 王晓明, Bächer, “基于振动的机器人动作重定向”, 中文信息学报. 图., vol. 38, no. 4, pp. 1-14, 2019。  
[2]熊仁杰, 李伟, 梁艳, 毛艳, 张军, “基于动态动作原语的双臂手势动作重定向,” 进程, 国际工程学. 相依的机器人. 自动售货机., 2021, pp. 8195-8201。  
[3]李志强, “基于机器人的人体运动定位”, 机械工程学报, 第 18 期, 国际工程学. Conf. Humanoid Robots, 2018, pp. 425-432。  
[4]王志强, “基于机器人运动学逆解的机械臂运动学研究”, 机械工程学报, 程序, IEEE/RSJ 学报. 机密, 情报. 机器人系统. ( 猫. No 03 CH37453), 2003, vol. 2, pp. 1407-1412。

[5]崔世生, 金, “一种基于运动数据的人形机器人控制管道”, IEEE/RSJ 学报, 程序. 机密, 情报. 机器人系统., 2019, pp. 4373-4380。  
[6]王仁, 左晓霞, 王仁, 程峰, 杨仁, “一种基于深度传感器的人-机器人运动重定向方法”, IEEE 国际版, 程序. 机密, 机器人. 自动售货机., 2017, pp. 5369-5376。  
[7]李建军, “基于学习潜空间的机器人运动规划”, IEEE. 自动售货机. 列托人., vol. 4, no. 3, 第 2407-2414 页, 2019 年 7 月。  
[8]王小明, 王晓明, 王晓明, “基于模糊神经网络的嵌入式控制模型研究”, 计算机工程学报. 系统. 生态学报, 2015 年第 28 卷, arXiv:1506.07365。  
[9]张晓明, 张晓明, 张晓明, 等. 基于神经网络的机器人运动控制方法 [j]. 机械工程学报, 2018, 32(4):555 - 557。  
[10]李志强, 李志强. 李高, “C-3PO:基于强化学习的人-机器人运动目标的循环三相优化”, 在 proc. IEEE 国际版. 机密, 机器人. 自动售货机., 2020, pp. 8425-8432。  
[11]崔淑, 潘明, 金, “基于共享潜空间的仿人机器人非参数运动重定向”, 程序.:科学. 系统., 2020 年 7 月。  
[12]朱志强, 胡辉, “机器人装配过程中机器人学习的实证研究”, 机械工程, vol. 7, no. 12. 第 2 期, 第 17 页, 2018。  
[13]张晓明, “软机器人装配策略的研究”, 程序, IEEE/RSJ 学报. 机密, 情报. 机器人系统., 2020, pp. 8309-8315。  
[14]李高, 金, 吴文杰, 李高, “混合质量的自动驾驶技术”, IEEE/RSJ 学报, 程序. 机密, 情报. 机器人系统., 2020, pp. 5425-5430。  
[15]蔡春林, 梁玉生, 闫伟, “基于人工智能的机器人技能零空间分析”, IEEE, 国际版, 程序. 机密, 机器人. 自动售货机., 2020, pp. 7668-7675。  
[16]李培平, 李鹏, 李志强, 阿伯曼, D. Lischinski. 陈, “用于深度运动目标的骨骼感知网络”, ACM 翻译. 图., vol. 39, no. 4, 第 62 页, 2020。  
[17]张晓明, 吴晓明, 张晓明, 阿伯曼, D. Lischinski, 陈, D. Cohen-Or, “基于特征不确定的运动重定向学习”, 2019, arXiv:1905.01680。  
[18]李晓明, 李晓明, 李晓明, 杨仁, “基于神经网络的无监督运动重定向”, IEEE 机密, 计算, 程序. Vis. Pattern recognition ., 2018, pp. 8639-8648。  
[19]张晓明, 张晓明, 张晓明, “基于深度 sdf 的连续符号距离函数学习方法”, IEEE/CVF 机密, 计算, 程序. Vis. Pattern recognition ., 2019, pp. 165-174。  
[20]王小明, 王晓明, 王晓明, 等. 自编码变分贝叶斯算法[j]. 中文信息学报, 2013, (arXiv): 344 -344。  
[21]张斌, 张海涛, “基于神经潜优化的肢体语言学习方法研究”, 中国语言学报, 2015, 44(1):442 - 448。  
[22]熊玉林, 闫淑娟, “基于时序图卷积神经网络的动作识别”, 程序, 第 32 期, 人工智能配置. 智能., 2018, pp. 7444-7452。  
[23]李明, 赵戡, 张斌, 王勇, 田青, “基于动态多尺度图神经网络的人体运动预测”, IEEE/CVF 配置, 计算. Vis. Pattern recognition ., 2020, pp. 214-223。  
[24]曾安, 孙晓明, 杨丽丽, 赵戡, 刘明, 徐清, “基于骨骼图神经网络的硬三维姿态估计”, IEEE/CVF, 程序. 配置计算. Vis., 2021, pp. 11436-11445。  
[25]陈晓明, “面向游戏、机器人和机器学习的 python 仿真模块 Pybullet(2016-2021)”, [在线]. 可用http://pybullet.org  
[26] J.Schulman, F.Wolski P.Dhariwal, A.Radford, 安藤. Klimov, “最近邻策略优化算法”, 2017, arXiv:1707.06347。  
[27]张建军, “基于数据的离散型栅格数据传输距离计算”, 计算机工程学报, 2004, 24(4):559 - 564。